

DocTransAgent

使用说明

AI 驱动的海外文档翻译与知识库智能代理

基于 GMI Cloud 多模型推理引擎

版本 1.0 | 2026年05月22日

黑客松参赛项目

系统概述

什么是 DocTransAgent ?

DocTransAgent 是一个面向出海企业的 AI 文档翻译与知识库管理智能代理。它能够自动解析上传的中文文档（PDF、DOCX、MD、TXT），调用 GMI Cloud 多模型推理引擎将文档翻译为英文（及其他 10 种语言），并将翻译结果索引至跨语言向量知识库中，支持语义搜索与 RAG 智能问答。

核心能力

- **智能文档解析：**
自动识别文档结构、段落和术语，支持 PDF / DOCX / MD / TXT 四种格式。
- **术语强制翻译：**
通过术语表（Glossary）确保翻译一致性，可手动编辑或由 LLM 自动提取。
- **10 种语言支持：**
中文 → 英文 / 日文 / 韩文 / 法文 / 德文 / 西班牙文 / 葡萄牙文 / 阿拉伯文 / 俄文。
- **跨语言知识库：**
向量索引支持跨语言语义搜索——中文查询可检索英文文档，反之亦然。
- **RAG 智能问答：**
基于知识库的检索增强生成（RAG），流式回答并附带原文引用。
- **ROI 仪表盘：**
实时对比 AI 翻译成本 vs 人工翻译成本，展示投资回报分析。
- **GMI 多模型流水线：**
结构解析 / 翻译 / 嵌入 / 问答分别使用不同最优模型，流水线可视化。

适用场景

- 出海企业将中文产品手册、合规文档、品牌指南快速翻译为多语言版本。
- 跨国团队建立统一的跨语言知识库，消除信息孤岛。
- 海外业务人员通过中文查询英文文档，或海外员工以英文检索中文资料。

环境要求

硬件与操作系统

- 操作系统：macOS 或 Linux（Windows 可通过 WSL2 运行）
- 内存：建议 4GB 以上
- 磁盘：至少 500MB 可用空间

软件依赖

- Python : 3.10 及以上版本
- Node.js : 18 及以上版本 (前端构建)
- npm / yarn : 包管理器 (随 Node.js 安装)

GMI Cloud API Key

DocTransAgent 的核心翻译和问答能力由 GMI Cloud 多模型推理引擎驱动。使用前需注册 GMI Cloud 账号并获取 API Key (访问 <https://console.gmicloud.com>) 。

提示：

如果没有 API Key，系统支持 Mock 模式运行。Mock 模式下翻译和问答功能将返回模拟结果，但文档上传、解析、知识库索引等全部前端交互均可正常体验。

验证安装

运行以下命令确认 Python 和 Node.js 版本：

```
python3 --version # 应输出 Python 3.10+  
node --version    # 应输出 v18+
```

运行以下命令测试 GMI Cloud API 连接：

```
python3 scripts/test_gmi_connection.py
```

快速开始

1. 配置环境变量

复制示例配置文件并根据需要编辑：

```
cp backend/.env.example backend/.env
```

打开 backend/.env 文件，填入您的 GMI Cloud API Key：

```
GMI_API_KEY=gmi-xxxxxxxxxxxxxxxxx  
# 其余配置保持默认即可
```

提示：

Mock 模式跳过此步骤。系统将以模拟方式运行所有 AI 功能。

2. 测试连接

```
cd backend  
python3 ../scripts/test_gmi_connection.py
```

如看到连接成功提示，表示 GMI Cloud API 配置正确。

3. 初始化演示数据（可选）

```
python3 scripts/seed_demo_data.py
```

该脚本将导入 3

份中文演示文档（品牌指南、合规政策、产品手册）和一组常用术语表条目到系统中，方便快速体验完整功能。

4. 启动应用

```
./run.sh
```

启动脚本将同时运行后端 API 服务（FastAPI, 端口 8000）和前端开发服务器（React, 端口 3000）。启动完成后：

- 前端界面：<http://localhost:3000>
- API 文档（Swagger）：<http://localhost:8000/docs>
- API 文档（ReDoc）：<http://localhost:8000/redoc>

提示：

首次启动时后端会自动安装 Python 依赖（约需 1-2 分钟）。前端 node_modules 会在首次 npm install 时安装。

5. 开始使用

打开浏览器访问

<http://localhost:3000>，您将看到仪表盘页面。点击「上传文档」按钮上传第一份中文文档，系统会自动解析文档结构，随后您可以执行翻译、索引和问答操作。

功能详解

1. 仪表盘 (Dashboard)

仪表盘是进入系统后的默认页面，提供全局数据概览和 ROI 分析。

统计卡片

页面顶部展示 4

张关键数据卡片：总文档数、已翻译文档数、知识库条目数、术语表术语数。卡片以实时数据驱动，随操作动态更新。

GMI Cloud 多模型流水线可视化

仪表盘中央展示 GMI Cloud 五步推理流水线：

文档解析 → 术语提取 → 机器翻译 → 向量嵌入 → 知识检索

每步标注了所使用的模型（如 GLM-4 负责结构解析，Gemini 2.5 Flash 负责翻译等），让用户直观了解 AI 工作流程。

ROI 对比分析

仪表盘底部提供投资回报分析图表，横向对比：

- AI 翻译总成本（基于 GMI Cloud Token 用量计算）
- 同等字数人工翻译预估成本（按行业均价 \$0.08-\$0.15/字符）
- Token 用量按模型分解展示

提示：

ROI 数据会累计所有历史文档的翻译成本。可在仪表盘上直观看到 AI 翻译相比人工翻译节省了多少费用。

2. 文档上传与翻译

上传模块是系统的核心入口，完整流程如下：

步骤 1：上传文档

在「上传」页面点击上传区域或拖拽文件到上传区域。支持 PDF、DOCX、MD、TXT 四种格式。上传后系统自动解析文档结构并显示在文档列表中。

步骤 2：查看文档列表

文档列表展示每份文档的名称、类型、字数、上传时间和当前状态（待翻译 / 翻译中 / 已翻译 / 已索引）。

步骤 3：启动翻译

点击文档旁的「翻译」按钮。系统将文档发送至 GMI Cloud

翻译流水线，先提取术语、再分段翻译、最后应用术语表进行术语一致性校正。

步骤 4：跟踪进度

翻译过程中可看到实时进度条，展示已完成和总段落数。翻译完成后状态自动更新为「已翻译」。

步骤 5：索引至知识库

翻译完成后，点击「索引」按钮将双语文档存入向量知识库。索引完成后即可在知识库搜索和问答模块中使用。

注意：

文档大小限制为 10MB。超大文档建议拆分为多个章节分别上传，系统会自动维护文档间的关联关系。

3. 翻译对比审阅

翻译完成后，点击文档进入「翻译审阅」页面。该页面提供：

- 左右分栏对比：左侧原文、右侧译文，段落级对齐。
- 段落导航器：快速跳转到文档的任意段落。
- 术语表 A/B 对比：可开关术语表视图，查看 AI 翻译结果与术语表强制翻译的对比差异。
- GMI Cloud 流水线状态：显示当前文档的翻译模型、Token 用量和耗时信息。
- 双语导出：支持导出为双语对照格式。

4. 知识库搜索

知识库模块提供跨语言语义搜索能力。不同于传统关键词匹配，语义搜索能理解查询意图，即使查询语言与文档语言不同也能返回相关结果。

使用方式：

- 在搜索框输入查询关键词或问题（支持中文或英文）
- 选择搜索范围（全部 / 仅原文 / 仅译文）
- 查看搜索结果，每条结果包含相关度评分和来源文档信息
- 点击结果可跳转至文档详情页

搜索结果按语义相关度降序排列，最高 100

分。分数越高表示匹配度越好。页面同时展示知识库统计信息（总条目数、文档数、最后更新时间等）。

提示：

跨语言搜索示例：在中文查询框中输入「数据保护条例」，系统能检索到英文版 Compliance Policy 文档中关于 data protection regulation 的相关段落。

5. 智能问答 (RAG Q&A)

智能问答模块基于 RAG (Retrieval-Augmented

Generation) 架构，将用户问题与知识库中的相关文档段落结合，通过 GMI Cloud 大模型生成准确回答。

问答流程

1. 用户输入问题（支持中文或英文）
2. 系统将问题向量化并在知识库中检索最相关的文档片段
3. 检索结果与原始问题一起发送给 GMI Cloud 大模型
4. 模型生成带来源引用的流式回答

核心特性

- 流式输出 (SSE)：回答逐字生成，无需等待完整响应。
- 来源引用：每个回答附带原文段落链接，点击可查看出处。
- 会话管理：支持多轮对话，系统自动维护对话上下文。
- 推荐问题：系统根据知识库内容自动生成建议问题列表。
- 会话历史：自动保存问答历史，支持切换和清空。

注意：

问答质量取决于知识库内容的完整性和相关性。建议在提问前先将相关文档翻译并索引至知识库。

6. 术语表管理

术语表 (Glossary) 是 DocTransAgent

确保翻译一致性的核心机制。您可以手动添加术语条目，也可以让系统自动从文档中提取高频术语。

手动管理

- 添加术语：填写源语言术语、目标语言翻译和分类
- 编辑/删除：对已有术语进行修改或移除
- 按分类筛选：按业务领域分组管理术语（如法律、技术、市场等）
- 批量导入：支持 CSV / JSON 格式批量导入术语

LLM 自动提取

在术语表页面点击「自动提取」按钮，选择一份文档，系统将调用 GLM-4

模型分析文档中的高频专业术语，自动生成术语条目并填充到术语表中。提取结果可人工审核后确认添加。

提示：

建议上传第一批文档后先运行自动提取，审核结果后再进行批量翻译。这样翻译时就能自动应用术语表，确保全文档术语一致。

API 参考

以下列出 DocTransAgent 的所有 API 端点。完整的交互式 API 文档（包含请求/响应 Schema 和在线测试功能）请访问 <http://localhost:8000/docs>。

文档管理

方法	路径	说明
POST	/api/documents/upload	上传文档
GET	/api/documents	获取文档列表
GET	/api/documents/{id}	获取文档详情
DELETE	/api/documents/{id}	删除文档

上传文档示例

```
curl -X POST http://localhost:8000/api/documents/upload \
-F "file=@product_manual_zh.md" \
-F "language=zh"
```

翻译管理

方法	路径	说明
POST	/api/translate/{id}	启动翻译
GET	/api/translate/{id}/progress	翻译进度查询

启动翻译示例

```
curl -X POST http://localhost:8000/api/translate/1 \
-H "Content-Type: application/json" \
-d '{"target_language": "en"}
```

查询翻译进度示例

```
curl http://localhost:8000/api/translate/1/progress
```

知识库

方法	路径	说明
POST	/api/kb/index/{id}	索引入知识库
GET	/api/kb/search?q=...	语义搜索

语义搜索示例

```
curl "http://localhost:8000/api/kb/search?q=数据保护条例&top_k=5"
```

智能问答

方法	路径	说明
POST	/api/qa/ask	RAG 问答（非流式）
POST	/api/qa/ask/stream	RAG 问答（SSE 流式）

问答示例

```
curl -X POST http://localhost:8000/api/qa/ask \
-H "Content-Type: application/json" \
-d '{"question": "如何处理用户数据?", "session_id": "demo"}'
```

术语表与仪表盘

方法	路径	说明
GET/POST	/api/glossary	术语表列表 / 新增
GET/PUT/DELETE	/api/glossary/{id}	术语详情 / 更新 / 删除
POST	/api/glossary/auto-extract	LLM 自动提取术语
GET	/api/dashboard/stats	仪表盘统计数据
GET	/api/export/{id}/bilingual	导出双语对照文档

配置说明

.env 配置文件

所有配置项集中在 backend/.env 文件中，以下是完整配置项说明：

API 配置

```
# GMI Cloud API Key（必填，Mock 模式可留空）
GMI_API_KEY=gmi-xxxxxxxxxxxxxxxxx

# GMI Cloud API 地址（通常无需修改）
GMI_BASE_URL=https://api.gmicloud.com/v1
```

模型选择

DocTransAgent 采用多模型策略，不同任务使用不同模型以兼顾效果与成本：

配置项	默认值	用途
MODEL_TRANSLATE	gemini-2.5-flash	文档翻译
MODEL_QA	deepseek-v3	RAG 问答
MODEL_STRUCTURE	glm-4	文档结构解析与术语提取
MODEL_EMBED	qwen3-embedding-8b	向量嵌入

提示：

模型选择建议：

- gemini-2.5-flash：翻译质量高且速度快，适合大批量文档处理。
- deepseek-v3：推理能力强，适合复问答场景。
- glm-4：中文理解能力好，适合中文文档结构解析。
- qwen3-embedding-8b：嵌入质量高，支持多语言语义匹配。

配置项示例

```
GMI_API_KEY=gmi-xxxxxxxxxxxxxxxxx
GMI_BASE_URL=https://api.gmicloud.com/v1
MODEL_TRANSLATE=gemini-2.5-flash
MODEL_QA=deepseek-v3
MODEL_STRUCTURE=glm-4
MODEL_EMBED=qwen3-embedding-8b
MOCK_MODE=false
MAX_UPLOAD_SIZE_MB=10
```

常见问题

Q: Mock 模式是什么意思？

A: Mock 模式是系统内置的演示模式。在此模式下，翻译和问答功能不会调用 GMI Cloud API，而是返回预设的模拟结果。Mock 模式让您无需 API Key 即可体验系统的完整前端交互流程，包括文档上传、解析、翻译进度展示、知识库搜索界面和问答 UI。

Q: 支持哪些语言的翻译？

A: 目前支持 10 种语言的双向翻译：中文 (zh)、英文 (en)、日文 (ja)、韩文 (ko)、法文 (fr)、德文 (de)、西班牙文 (es)、葡萄牙文 (pt)、阿拉伯文 (ar)、俄文 (ru)。翻译方向以中文为源语言，目标语言可从以上列表中选择。

Q: 翻译成本如何？

A: 翻译成本取决于文档字数和所选模型。以 gemini-2.5-flash 为例，约 \$0.15-\$0.35 / 百万 tokens（输入+输出合计）。一篇 10,000 字的中文文档翻译成本约 \$0.02-\$0.05。仪表盘上的 ROI 分析模块可实时查看累计成本和与人工翻译的对比。

Q: 文件大小和格式有什么限制？

A: 单个文件大小限制为 10MB。支持的格式：PDF、DOCX、MD、TXT。对于超大文档，建议按章节拆分后分别上传。PDF 文件需为文本型 PDF（非扫描图片），扫描件需先 OCR 处理后再上传。

Q: 如何更新术语表？

A: 有两种方式：1) 在术语表页面手动添加/编辑/删除术语条目；2) 使用「自动提取」功能让 AI 从已上传文档中识别高频术语。更新术语表后，后续翻译会自动应用新术语，但已完成的翻译不会自动更新。

Q: 知识库中的数据如何更新？

A: 每份文档翻译完成后需要手动点击「索引」按钮将双语内容写入向量知识库。如果文档原文或译文有更新，需要重新索引以更新知识库中的向量表示。

Q: 如何导出翻译结果？

A: 在翻译审阅页面，点击「导出」按钮可将文档导出为双语对照格式。也有 API 端点 GET /api/export/{id}/bilingual 可供程序化调用。

Q: 系统如何确保数据安全？

A: 所有文档处理和翻译调用均在服务端完成。API Key 通过环境变量配置，不会暴露给前端。建议在生产环境部署时启用 HTTPS 和访问认证。

脚本工具

[test_gmi_connection.py](#)

测试 GMI Cloud API 连接状态，验证 API Key 是否有效：

```
python3 scripts/test_gmi_connection.py
```

输出示例：

- 成功：显示可用模型列表和连接延迟
- 失败：提示 API Key 无效或网络不可达，并给出排查建议

[seed_demo_data.py](#)

向系统导入演示数据，包括 3 份中文文档和一组常用术语：

```
python3 scripts/seed_demo_data.py
```

演示文档：

- brand_guide_zh.md — 品牌策略手册
- compliance_zh.md — 合规与数据保护政策
- product_manual_zh.md — 产品技术手册

导入后可直接体验翻译、知识库搜索和问答功能。

注意：

seed_demo_data.py 会向系统中添加数据。如系统已有数据，请确认是否重复导入。

使用技巧与最佳实践

翻译 workflow 建议

步骤 1：先建术语表

在上传文档之前或刚上传第一批文档后，使用自动提取功能建立术语表。审核确认术语后，后续所有翻译都会自动应用术语表，确保全项目术语一致。

步骤 2：分批次翻译

对于大量文档，建议分批上传和翻译，每批 3-5 份文档，逐批审核质量。这样可以及时发现问题并调整术语表。

步骤 3：翻译后审阅

每份文档翻译完成后，进入「翻译审阅」页面进行段落级对比检查。如发现术语不一致之处，更新术语表后重新翻译该段落。

步骤 4：全部索引

审阅通过的文档全部索引至知识库。索引后的文档才能被搜索和问答模块使用。

问答使用技巧

- 问题越具体，回答越精确。避免过于宽泛的问题如「文档内容是什么」。
- 利用多轮对话逐步深入。系统会保留对话上下文，可以追问细节。
- 关注来源引用。每个回答都附带原文段落链接，点击即可核实信息。
- 中英文混合提问。系统支持跨语言检索，用中文提问可以找到英文文档内容。

成本优化建议

- 模型选择：gemini-2.5-flash 翻译成本最低且速度最快，适合大批量翻译。
- 批量处理：尽量避免单个文档反复翻译，一次翻译到位更经济。
- 术语表复用：建立好术语表后，多个文档可共享使用，无需为每个文档重新提取。
- 监控仪表盘：定期查看仪表盘的 Token 用量分解，了解各模型的调用成本分布。

DocTransAgent — AI 驱动的海外文档翻译与知识库智能代理

基于 GMI Cloud 多模型推理引擎 | 黑客松参赛项目

© 2026 DocTransAgent Team. All rights reserved.